Informe Ejecutivo: Sistema "Deep Retention"

Para: Dirección de Estrategia y Rentabilidad de Clientes y Junta Directiva. **De:** Equipo de Desarrollo e Inteligencia de Negocios. **Fecha:** noviembre 2026.

La retención indiscriminada destruye margen. Deep Retention combina una red neuronal que estima la probabilidad de fuga de cada cliente con una regla financiera que solo autoriza un incentivo cuando la ganancia neta esperada para el banco es positiva. Todas las cifras de este informe se reproducen ejecutando `python train.py` (semilla fija) sobre el dataset entregado (10.000 clientes).

Nota de reproducibilidad: con la semilla fija, cada entorno produce siempre el mismo resultado. Entre entornos distintos (por ejemplo Windows con Python 3.12 frente a Google Colab con Python 3.13) las librerías numéricas redondean distinto y las cifras pueden variar ligeramente: en Colab se obtuvo ROC-AUC 0,8674 (aquí 0,8669) y ROI en Test de 425,5% (aquí 426,9%). La variación es menor a 0,5% y no cambia ninguna conclusión. Las cifras de este informe corresponden a los artefactos publicados en el repositorio.

---

1. Resumen de Impacto Financiero y Retorno

Indicador	Cartera completa	Validación fuera de muestra (Test)
Volumen total de clientes analizados	10.000	1.500
Capital en riesgo (P(fuga) >= 0,30)	$195.372.531	$31.155.662
Capital en riesgo crítico (P(fuga) >= 0,65)	$63.081.374	$9.428.320
Capital de clientes rentables a intervenir	$195.372.531	$31.155.662
Capital esperado a retener (P x Efectividad x Saldo)	$55.117.522	$8.784.358
Inversión total en campañas de fidelización	$320.660	$50.220
Ganancia neta esperada	$1.338.130	$214.411
Retorno sobre la inversión (ROI)	**417,3%**	**426,9%**
Clientes intervenidos (VIP / Bonificación)	1.877 (1.486 / 391)	291 (234 / 57)
Clientes con "Salida Permitida" (deficitarios)	313 (87)	49 (14)

- **ROI** = Ganancia neta esperada / Inversión. La ganancia ya descuenta el costo de cada incentivo.
- Todo el capital en riesgo pertenece a clientes rentables: los 313 clientes de "Salida Permitida" tienen saldo cero y sus comisiones no cubren el costo de servicio o el incentivo. Bloquearlos evita $18.780 de gasto sin retorno.
- La cartera completa incluye clientes usados para entrenar la red; la columna de Test (clientes nunca vistos) confirma que el ROI se sostiene fuera de muestra.

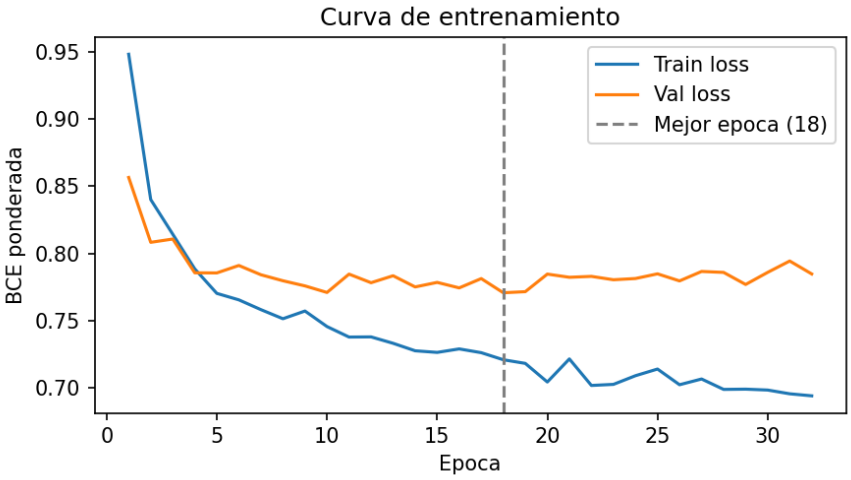
---

2. Arquitectura de la Solución y Diagnóstico de Fuga

Configuración de la red neuronal

- **Datos:** `Customer-Churn-Records.csv`, partición estratificada 70% entrenamiento / 15% validación / 15% test (tasa de fuga 20,4% en los tres).
- **Preprocesamiento sin fuga:** `StandardScaler` en 8 variables numéricas y `OneHotEncoder` en país y género, ajustados solo con entrenamiento (13 entradas).
- **Variables excluidas:** `Complain` coincide con el abandono en el 99,86% de los clientes; con ella el ROC-AUC sube a 0,9987, lo que delata fuga de información, por lo que se excluye. `Satisfaction Score`, `Card Type` y `Point Earned` no tienen relación con la fuga (correlación cercana a 0) y no mejoran el modelo.
- **Perceptrón multicapa (PyTorch):** Densa 128 + BatchNorm + ReLU + Dropout 0,25; Densa 64 + ReLU + Dropout 0,15; salida de 1 neurona con sigmoide.
- **Desbalance:** `BCEWithLogitsLoss` con `pos_weight = 3,91` (negativos / positivos).

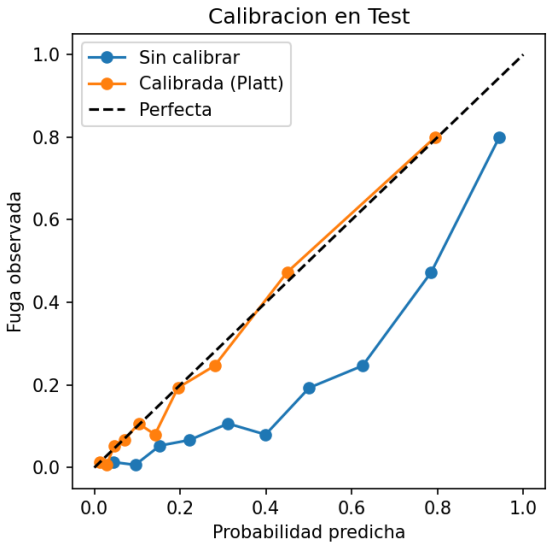
- **Entrenamiento:** Adam (lr 0,001, L2 1e-4), lotes de 64, Early Stopping con paciencia de 14 épocas sobre `val_loss`. Mejor época: 18 de 32.
- **Calibración:** la ponderación de clases infla las probabilidades (media 0,41 frente a una tasa real de 0,20). Como la regla financiera usa la probabilidad directamente, se aplica Platt scaling ajustado en validación y guardado dentro del modelo.



Curva de entrenamiento: pérdida de entrenamiento y validación con la mejor época

Métricas de diagnóstico técnico (conjunto de Test)

Métrica	Sin calibrar	Calibrada (en producción)
ROC-AUC	0,8669	0,8669
Precision-Recall AUC (línea base 0,204)	0,7039	0,7039
Brier score (menor es mejor; constante = 0,162)	0,1568	**0,1019**
Error de calibración esperado (ECE)	0,2042	**0,0226**
Probabilidad media vs tasa real	0,408 vs 0,204	0,212 vs 0,204

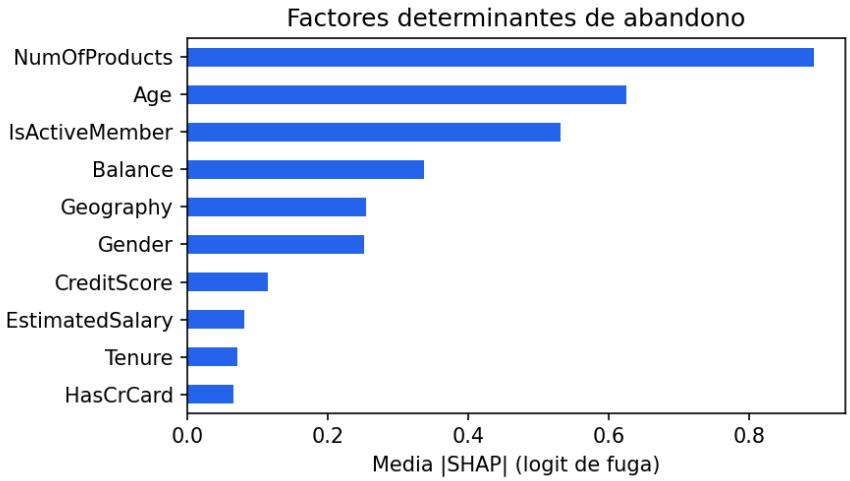


Curva de calibración en Test antes y después de Platt scaling

La calibración no cambia la capacidad de ordenar clientes (mismo ROC-AUC) pero hace que un 30% de probabilidad signifique de verdad 3 de cada 10 clientes. En la cartera, la fuga real por segmento coincide con la probabilidad media predicha (por ejemplo, 8,7% real frente a 10,1% predicho en clientes estables).

Factores determinantes de abandono (SHAP)

Importancia global medida con SHAP (`GradientExplainer`) sobre 500 clientes de Test, agregando las columnas one-hot por variable original.



Importancia SHAP por variable

1. **Número de productos (`NumOfProducts`):** con 3 productos abandona el 83% y con 4 el 100%, frente a 7,6% con 2 productos. La sobrecarga de productos es la principal señal de fuga.
2. **Edad (Age):** la fuga sube de 7,5% (hasta 30 años) a 56% entre 50 y 60 años.
3. **Actividad (`IsActiveMember`):** los clientes inactivos abandonan casi el doble (26,9% frente a 14,3%).

Les siguen el saldo (los clientes con saldo abandonan 24% frente a 14% sin saldo) y el país (Alemania 32% frente a 16% en Francia y España).

---

3. Matriz de Decisión Comercial y Rentabilidad

Regla aplicada a cada cliente con P(fuga) >= 0,30, para cada incentivo elegible:

Ganancia Neta Esperada = P(fuga) x Efectividad del Incentivo x Margen del Cliente - Costo del Incentivo

Se elige el incentivo con mayor ganancia y solo se ejecuta si es mayor a cero. Margen anual del cliente = saldo x 2,5% (margen neto) + salario x 0,4% x número de productos (comisiones) - $150 (costo de servicio). El margen puede ser negativo: así se identifican los clientes deficitarios.

Segmento	Probabilidad red	Valor patrimonial	Decisión del sistema	Incentivo asignado	Clientes	Costo unit.	Costo total	Margen neto proyectado
A: Alto Valor	>= 0,30 (media 0,58; 487 con >= 0,65)	Saldo superior (>= $80.000, media $125.359)	Retención Prioritaria	Gestor VIP y Tarifa Plana (50% efectividad)	1.486	$200	$297.200	+$1.261.930
B: Valor Medio	>= 0,30 (media 0,66; 195 con >= 0,65)	Saldo medio (media $23.246)	Retención Automatizada	Bonificación Transaccional (30% efectividad)	391	$60	$23.460	+$76.200
C: No Rentable	>= 0,30 (media 0,50)	Saldo cero / deficitario (87 con margen negativo)	Salida Permitida	Sin intervención	313	$0	$0	Ahorro operativo: $18.780 evitados
D: Estable	< 0,30 (media 0,10)	Cualquier saldo	Sin Acción Requerida	Mantenimiento Ordinario	7.810	$0	$0	Estable
Total					**10.000**		**$320.660**	**+$1.338.130**

- El segmento C lo determina la fórmula, no un umbral de saldo: un cliente con saldo bajo pero buenas comisiones sí se retiene (segmento B).
- La matriz del enunciado no define la banda 0,30 a 0,65; se le aplica la misma fórmula, porque la probabilidad ya pondera el beneficio esperado.

- Fuga real observada por segmento: A 63%, B 64%, C 56%, D 8,7%.

Supuestos financieros (ajustables en el simulador de la aplicación)

Parámetro	Valor	Uso
Margen neto sobre saldo (NIM)	2,5% anual	Margen del cliente
Comisiones	0,4% del salario por producto	Margen del cliente
Costo de servicio	$150 anual	Permite márgenes negativos
Gestor VIP y Tarifa Plana	$200, 50% de efectividad	Solo saldo >= $80.000
Bonificación Transaccional	$60, 30% de efectividad	Cualquier cliente

---

4. Operación de la Aplicación en Sucursales

Procedimiento del gestor de cuentas

1. Abrir la aplicación (`streamlit run app/app.py`) y entrar en la pestaña **Buscador por Cliente**.
2. Seleccionar el `CustomerId` del cliente (o cargar un perfil nuevo con sus datos).
3. Revisar el diagnóstico: probabilidad de fuga calibrada, margen anual, mejor ganancia neta esperada, costo del incentivo y el gráfico SHAP con las razones del riesgo.
4. Ejecutar la decisión: **Retención Prioritaria** (asignar gestor VIP y tarifa plana), **Retención Automatizada** (acreditar la bonificación transaccional), **Salida Permitida** (no ofrecer descuentos ni bonos; atención estándar) o **Sin Acción Requerida**.
5. Registrar en el CRM la acción y si el cliente se quedó, para medir la efectividad real de cada incentivo.

Gerencia usa el **Panel de Cartera** (capital en riesgo, capital a intervenir, inversión y ROI) y el **Simulador de Parámetros** para recalcular la cartera con otros costos, efectividades, márgenes o umbrales.

Mantenimiento del modelo

- **Mensual:** actualizar la cartera y revisar la deriva de las variables principales (productos, edad, actividad, saldo) y la calibración (ECE en clientes recientes).
- **Trimestral:** reentrenar con `python train.py` incorporando las salidas observadas; aceptar el nuevo modelo solo si iguala o mejora el ROC-AUC y el ECE en Test. Los tests automáticos (`pytest`) deben pasar antes de publicar.
- **Tras cada campaña:** reemplazar las efectividades supuestas (50% y 30%) por las medidas en el CRM.

---

5. Conclusiones y Próximos Pasos

- El sistema concentra el presupuesto en 1.877 clientes rentables y bloquea el gasto en 313 que no lo compensan, con un ROI esperado de 417% (427% en clientes nunca vistos).
- La calibración de probabilidades es indispensable: sin ella, la ganancia esperada se habría sobrestimado porque la red predecía el doble de fuga real.
- El mayor riesgo del modelo financiero son las efectividades supuestas de los incentivos; la prueba piloto debe medirlas.

Prueba piloto y despliegue

Semanas	Actividad
1 a 2	Capacitación de gestores en 5 sucursales piloto (Francia, Alemania y España) y carga de la cartera.
3 a 8	Piloto A/B: grupo de control con la política actual frente a grupo Deep Retention. Medir retención, costo y margen.
9	Recalibrar efectividades y costos con los resultados; reentrenar el modelo.
10 a 12	Despliegue gradual en toda la red e integración con el CRM.